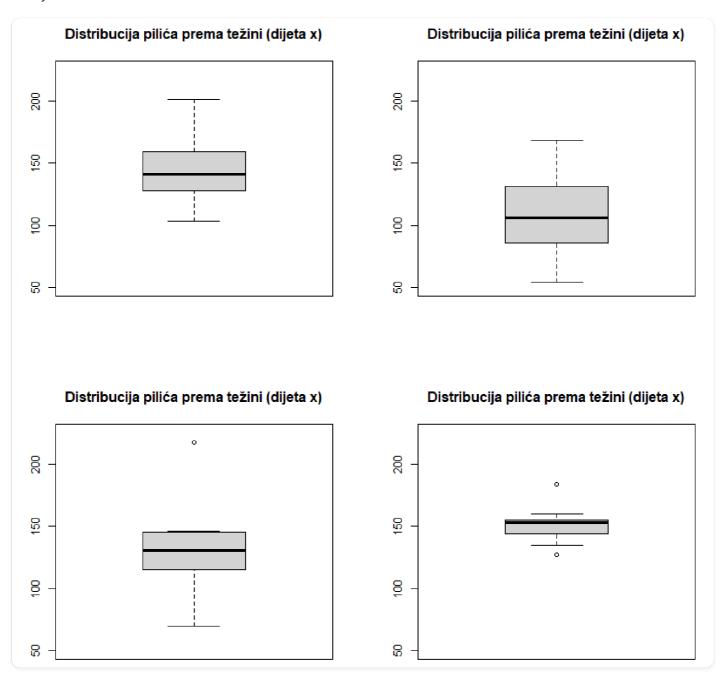
Samostalni zadatak za vježbu 5

Radit ćemo s podacima ChickWeight, koji sadrže informacije o težini pilića tijekom različitih tjedana i njihovoj prehrani. Cilj je analizirati podatke, vizualizirati distribucije i usporediti rezultate između različitih dijeta.

Priprema podataka

- 1. Učitajte skup podataka ChickWeight kao data.frame u varijablu cw
- 2. Izmijenite nazive stupaca na hrvatski jezik:
 - weight → tezina
 - Time → tjedan
 - o Chick → pilic
 - o Diet → dijeta
- 3. Kreirajte zasebne data.frame objekte za odabrane piliće:
 - o pilic1: podaci za pilića 1
 - o pilic27: podaci za pilića 27
 - o pilic34: podaci za pilića 34
 - o pilic50: podaci za pilića 50
- 4. Prikažite distribuciju težine pilića u 12. tjednu za svaku dijetu koristeći četiri odvojena boxplota boxplot() (po dva u svakom retku par() mfrow)
 - o Ograničite raspon osi y od 50 do 225 ylim
 - Naslovi grafova main:
 - Distribucija pilića prema težini (dijeta 1)
 - Distribucija pilića prema težini (dijeta 2)
 - Distribucija pilića prema težini (dijeta 3)
 - Distribucija pilića prema težini (dijeta 4)

Primjer.



Analiza distribucije

- 5. Koja dijeta ima najveći raspon vrijednosti težine?
 - o Zaključiti iz boxplot grafikona
- 6. Postoje li stršeće vrijednosti (outlieri)?
 - o Ako postoje, za koju dijetu?
 - o Jesu li to minimalne ili maksimalne vrijednosti?
 - o Zaključiti iz boxplot grafikona
- 7. Izračunajte sljedeće statističke mjere za dijetu 1:
 - Raspon vrijednosti diff(range(x))
 - Interkvartilni raspon IQR()

8. Izračunajte Pearsonov koeficijent asimetrije za dijetu 2 i dijetu 4.

$$\alpha = \frac{\mu_3}{\sigma^3}$$

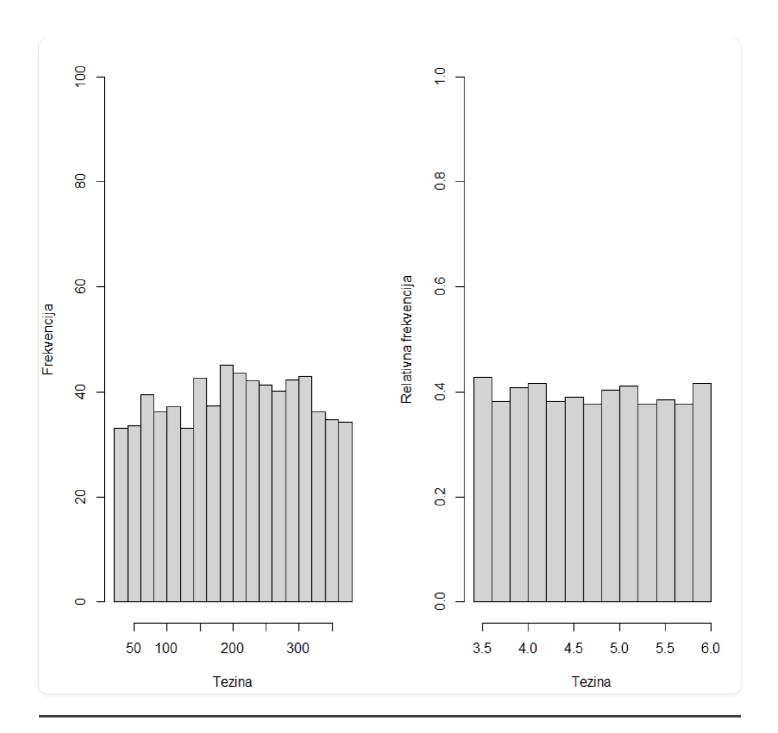
$$\mu_3 = \frac{\sum (x - \bar{x})^3}{N}$$

- \circ alpha = mu/sd(x) \wedge 3
- \circ mu = sum((x mean(x)) \wedge 3)/N
- 9. Za koju je dijetu asimetrija veća?
 - o 0 = simetrična distribucija
 - o 0 0.5 = približno simetrična distribucija
 - o 0.5 1 = umjerena asimetrija
 - o >1 = izražena asimetrija

Histogram distribucije težine

- 10. Napravite histogram distribucije težine pilića hist():
 - o Prikaz svih pilića pomoću histograma s 15 razreda breaks
 - o Naslov: Distribucija pilića prema težini
 - o Veličina slova u naslovu smanjena na 75%
 - Nazivi osi:
 - x-os: Težina
 - y-os: Frekvencija
 - o Ograničite raspon y-osi na 0 do 100 ylim
- 11. Na temelju histograma, je li težina pilića normalno distribuirana?
- 12. Transformirajte podatke kako bi distribucija bila bliža normalnoj te prikažite novi histogram pored postojećeg:
 - o probability = TRUE
 - o Naslov: Distribucija pilića prema težini (log)
 - Nazivi osi:
 - x-os: Težina
 - y-os: Relativna Frekvencija

Primjer.



Usporedba pilića izražena u standardnim devijacijama

- 13. Izračunajte prosječnu težinu pilića u 8. i 12. tjednu.
- 14. Izračunajte standardnu devijaciju sd() težine pilića u 8. i 12. tjednu.
- 15. Tko je postigao bolji napredak izražen u standardnim devijacijama?
 - o Pilić 1 u 8. tjednu ili pilić 27 u 12. tjednu?
 - Standardizacija: (x mean(x))/sd(x)

Usporedba dijeta

- 16. Izračunajte prosječnu težinu pilića za svaku dijetu.
- 17. Izračunajte standardnu devijaciju težine pilića za svaku dijetu.

- 18. Na kojoj su dijeti pilići u prosjeku postigli najveću težinu?
- 19. Je li aritmetička sredina dovoljno reprezentativna za tu dijetu?
 - o Izračunat koeficijent varijacije: (sd(x)/mean(x))*100